

基于重定向轨迹的闭环抓取策略学习

宛乐康

1. 为什么有了轨迹还要训练策略

基础任务得到的是一条条可以直接重放的目标手轨迹。直接重放很像按照事先录好的路线开车：每个时刻该走到哪里都已经确定，但执行过程中并不会根据实际偏差主动修正。抓取对这种偏差尤其敏感——指尖相差几毫米，就可能从“夹住物体”变成“擦着物体滑过去”。因此进阶任务的目标，是让神经网络在每个物理步读取当前状态，并根据手和物体此刻的真实关系调整动作，把开环轨迹变成具有一定纠错能力的闭环策略。

我们只使用基础任务中通过“运输合格”筛选的轨迹，Linker、XHand 和 Wuji 分别保留 153、501 和 557 条。每个类别有两个物体实例，其中一个实例的 8 条轨迹用于训练、2 条用于验证，另一个实例的 10 条全部用于测试。这样测试集由 50 个训练时没有见过的物体实例组成，共 500 条任务；同一物体的不同轨迹不会同时出现在训练和测试中，避免模型只是记住物体外形。

策略每一步看到的内容包括手的关节与运动状态、物体相对手掌的位置和速度、是否发生接触、当前处于接近/闭合/抬升哪个阶段、上一时刻动作，以及 14 维物体形状描述。这里使用的是仿真可以直接提供的准确状态，因此研究重点是控制方法本身，还没有处理相机识别误差。


2. 我们如何一步步找到可行方法

第一步采用行为克隆，也就是最直接的监督学习：把当前观测输入网络，把专家在同一时刻的动作当作正确答案，通过降低两者的均方误差来训练。我们分别尝试了单帧 BC、读取三帧历史的 Temporal3，以及能表达多种动作可能性的 Diffusion Policy。离线训练时它们的 loss 都能明显下降，但放回 Isaac Gym 后，12 组“模型×目标手”组合几乎全部为零。原因不是网络完全没有学到，而是它在第一步产生小误差后，下一步看到的状态就不再是训练数据中的标准状态；误差会连续积累，最后表现为手指振荡、过早闭合或根本碰不到物体。这也说明离线 loss 很低不能代表机器人真正会抓取。

第二步改用 PhaseResidual。网络不再从头预测完整姿态，而只回答“在上一条命令上应该再增加或减少多少”，同时明确告诉它当前抓取阶段。随后使用类似 DAgger 的在线数据聚合：先让学生策略在仿真中实际执行，收集它自己走到的偏差状态，再由相位专家为这些状态补充修正动作并重新训练。这一修改把专家可行轨迹上的复现率提高到 Linker 12.3%、XHand 19.1%、Wuji 12.9%。三帧历史没有带来稳定提升，因为接近、闭合和抬升的相位本身已经提供了主要时间信息。

最终我们进一步采用 Residual PPO。它不要求网络重新发明整条抓取轨迹，而是把重定向轨迹当作一条可行的“主路线”：手腕继续按照专家轨迹移动，策略只在每一步给手指增加小幅修正。Actor 根据状态选择残差动作，Critic 则估计当前状态继续执行下去大概能得到多少回报。物体向上移动、保持接触和最终稳定成功会获得奖励，残差过大则受到惩罚，因此策略学习的是“什么时候需要偏离专家、偏离多少”，而不是随机探索完整动作空间。

训练使用两层各 128 单元的网络、20 个并行环境，每轮执行 240 步，共训练 300 轮。PPO 的学习率为 $3e-4$ ，折扣因子为 0.99，裁剪范围为 0.2。神经网络在 GPU 上训练，Isaac Gym 物理仍使用 CPU PhysX。




图：监督残差与PPO训练过程

3. 闭环测试结果

训练曲线中，监督残差的训练 loss 总体下降，但 Linker 的验证 loss 很早就开始反弹；PPO 的价值估计误差明显下降，不过训练成功率仍因只有 20 条并行训练任务而上下波动。因此我们没有根据某个漂亮的训练点下结论，而是统一使用未见物体上的物理闭环结果选择方法。

目标手	最优监督/Dagger复现率（注1）	Residual PPO复现率（注1）	500条全量成功率（注2）
LinkerHand O6	12.3%	54.3%	60/500（12.0%）
XHand	19.1%	54.1%	144/500（28.8%）
WujiHand	12.9%	45.4%	151/500（30.2%）

注1：只统计专家基线自身能够成功的测试任务，分母分别是 81、257、295，用来回答“参考轨迹可行时，策略能复现多少”。注2：统计完整 500 条任务，其中也包含专家轨迹本身失败的情况，用来回答“随机拿到一条测试任务，整个系统最终能成功多少”。



图：不同闭环策略的测试结果

Residual PPO 相比最好的监督策略提高了约 2.8 – 4.4 倍。Linker 的相对提升最大：它在基础重定向中最弱，却在专家可行子集上达到与 XHand 接近的复现率，说明自由度越少，手越依赖执行过程中的闭环微调。不过，Linker 全量成功率仍只有 12.0%，因为策略无法挽救大量本身就不可行的重定向轨迹。Wuji 的无约束轨迹在策略阶段也优于解剖修复版：修复版复现率为 36.3%、全量成功 83/500，低于无约束版的 45.4% 和 151/500。

4. 成功、失败与方法边界

从轨迹上看，成功策略通常没有做很夸张的动作，而是在专家手型附近略微增加或减小闭合量，使原本即将失去的接触重新稳定。三只手的代表性成功分别是 [Linker – Headphones](#)、[XHand – Piano](#)和 [Wuji – Blender](#)，其[最大/最终抬升](#)分别约为 33.0/33.0、33.9/33.9、32.9/32.9 cm。

失败主要有四种：接近位置已经偏离而没有接触；闭合过早把物体推开；抬升时接触不对称导致滑落；或者参考轨迹本身不可行。为了直观展示“曾经抬起并不等于抓取成功”，我们选择了三条抬升后滑落案例：[Linker – CerealBox](#)、[XHand – Fruit](#)和 [Wuji – Clock](#)。它们最高分别达到 37.0、38.3、39.4 cm；前两条最后落回初始高度以下 2.8 和 1.9 cm，第三条最终仅抬高 1.9 cm，因此都被严格规则判为失败。

这项结果还有一个重要边界。当前 Residual PPO 在测试时仍会获得该任务对应的重定向基线，手腕也沿专家轨迹运动，策略只负责修正手指。因此它更准确地说“参考轨迹条件下的闭环修正器”，而不是看到一个陌生物体后从零规划抓取。54%左右的数字说明它能较好复现可行专家，并不等于完全自主抓取成功率；系统级表现应同时看 12.0% – 30.2% 的全量结果。

如果继续改进，我会先让策略学习小范围腕部残差，使它能够修正接近误差；再用相机点云替代仿真中的准确物体状态，并加入触觉或接触反馈，让策略真正感知“是否夹住”和“是否正在滑动”。在完成这些基础能力后，再使用 Diffusion Policy 表达同一物体可能存在的多种抓取方式，才更有可能从“跟随一条参考轨迹”走向自主操作。